

智慧家庭语音交互意图理解评测现状

潘悦然^{1,2} 焦利敏^{3,4,5} 杨荣祥^{1,2} 崔庆用^{1,2} 姚昌松^{1,2} 徐翼^{1,2}

1. 美的集团股份有限公司 广东佛山 528311;
2. 美的集团 (上海) AI研究院 上海 201702;
3. 中国家用电器研究院 北京 100176;
4. 中家院 (北京) 检测认证有限公司 北京 100176;
5. 国家智能家居质量检测检验中心 北京 100176

摘要: 随着人工智能与物联网的融合,智慧家庭语音交互正由功能指令执行迈向需求理解和主动服务。意图理解作为服务的核心,其评测体系是衡量语音助手性能与用户体验的关键。综述了智慧家庭意图理解的评测现状,系统梳理了技术演进、评测数据集和指标体系。针对现有局限,提出评测体系面临的三大挑战:智能程度量化难、复杂交互覆盖不足、语料标准化缺失,并展望未来应构建以用户体验与情感智能为导向的新型评测框架。进一步提出三项建设路径:标准化数据与脚本、统一指标与报告协议、仿真与真实场景的迁移验证,为实现人本位智能评测提供参考。

关键词: 智慧家庭; 语音交互; 意图理解; 评测系统; 大语言模型

A survey on the evaluation of intent understanding in smart home voice interaction

PAN Yueran^{1,2} JIAO Limin^{3,4,5} YANG Rongxiang^{1,2} CUI Qingyong^{1,2} YAO Changsong^{1,2} XU Yi^{1,2}

1. Midea Group Co., Ltd. Foshan 528311;
2. AI Research Center, Midea Group (Shanghai) Co., Ltd. Shanghai 201702;
3. China Household Electric Appliance Research Institute Beijing 100176;
4. CHEARI (Beijing) Certification & Testing Co., Ltd. Beijing 100176;
5. National Smart Home Quality Supervision & Inspection Center Beijing 100176

Abstract: With the integration of artificial intelligence (AI) and the Internet of Things (IoT), smart home voice interaction is evolving from functional command execution to demand understanding and proactive service. Intent Understanding is the core of this service, and its evaluation system is crucial for measuring voice assistant performance and user experience. Reviews the current status of evaluation for intent understanding in smart home voice interaction, systematically summarizing its technical evolution, datasets, and metric systems. Addressing existing limitations, it identifies three major challenges: difficulty in quantifying intelligence, insufficient coverage of complex interactions, and lack of corpus standardization. Further envisions a human-centered evaluation framework guided by user experience and emotional intelligence. Also puts forward three construction paths: standardizing data and scripts, unifying metrics and reporting protocols, and validating transferability between simulation and real-world scenarios, providing a reference for achieving human-centric intelligence evaluation.

Keywords: Smart home; Voice interaction; Intent understanding; Evaluation framework; Large Language Model (LLM)

中图分类号: TM925; TP18

DOI:10.19784/j.cnki.issn1672-0172.2025.99.004

0 引言

随着人工智能 (AI) 与物联网 (IoT) 的飞速发展,智能家电正从简单的自动化设备演变为能够理解用户需求、提供主动服务的智

能终端。这种基于自然语言处理 (NLP) 的系统,使得用户能够通过直观的语音指令,无缝管理和控制多样化的家居环境,极大地增强了日常任务的效率与系统的可访问性。这一转变的核心在于对用户

指令文本和需求的准确把握,即智能家电意图理解任务^[1]。

意图理解是自然语言处理在语音交互领域的核心应用,主要负责从用户的语音输入中识别出其真实目的(例如,“控制灯光”“调节温度”“播放内容”等),是实现人机无缝交互的关键环节^[2]。特别是在复杂的智慧家庭环境中,指令往往涉及多设备协同、多轮对话和个性化情境,这对意图理解模型的准确性和鲁棒性提出了更高的要求。用户往往使用模糊、口语化甚至情绪化的表达来传达需求,例如“有点热”或“太暗了”,而非精确的控制指令。这对系统的语义解析、上下文推理、个性化适配提出了更高要求。随着计算机学科的发展,能使用与智慧家庭意图理解的技术经历了从早期的传统机器学习(Machine Learning, ML)到深度学习(Deep Learning, DL),再到当前大语言模型(Large Language Model, LLM)赋能的重大转变。随着美的、海尔、小米等头部企业在智慧家庭建设的发展,智能音箱、智能电视、家电控制中心等终端的大规模落地,产业界对评测体系的科学性与标准化提出了迫切需求。鉴于语音助手在现代生活中的核心地位及其复杂的AI驱动架构,系统化的评测体系对于确保产品质量、提升用户满意度、指导技术迭代以及实现商业成功至关重要。如何客观衡量语音交互系统在鲁棒性、自然度、响应准确率与跨场景泛化能力等方面的表现,已经成为学术界与产业界的共同挑战^[3-10]。

本文旨在系统综述智慧家庭语音交互意图理解的评测现状,基于现有的意图理解技术和评测体系,分析已有方法的技术特点与不足,总结学术研究与产业实践的差异与互补关系。在此基础上,进一步探讨当前评测体系面临的挑战,并展望未来的发展趋势与研究方向,为构建更完善的智能家居语音交互评测框架提供参考。

1 意图理解任务的技术演进

智慧家庭意图理解任务已从传统的意图识别与槽位填充(Intent & Slot Filling),演进为基于大模型的指令到控制序列生成的新范式。技术经历了由传统机器学习方法到深度学习框架的跨越式发展,并在近年逐步迈入以LLM为核心驱动的新阶段,呈现出方法论与体系架构的持续演进^[11]。

1.1 传统机器学习

早期的智慧家庭意图识别的任务范式聚焦于意图识别和槽位填充的子任务,主要依赖于传统机器学习方法,文本将使用TF-IDF、Word2Vec等方法提取特征向量化,在得到的特征上,使用随机森林(RF)、支持向量机(SVM)、XGBoost、CatBoost、LightGBM、多层感知器(MLP)等机器学习方法对指令的动作、设备、属性等意图标签进行预测^[12-14]。这些模型通常需要大量的特征

工程,并且对输入指令的鲁棒性较差。传统模型擅长处理基于模板的文本解析或文本的关键词提取。在处理口语化表达时的局限性,促使研究转向更强大的序列建模技术^[15-16]。

1.2 深度学习

深度学习的兴起标志着意图理解能力的一次重大飞跃。循环神经网络(RNN)及其变体长短期记忆网络(LSTM)能够更好地捕捉语音序列中的时间依赖关系和上下文信息^[15]。随后,以BERT为代表的预训练语言模型(PLMs)基于Transformer架构,通过大规模语料库的预训练,极大地增强了语义理解的深度和泛化能力^[16-17]。深度学习的NLP技术让Bixby、Google Assistant、Alexa等商业产品的语音助手能够处理购物、提醒、设备控制等多样指令^[15]。

尽管深度学习的方法增强了对泛化家电控制指令的意图理解,但仍面临指令模糊或复杂时的理解困难^[18]。在当前的评测基准中,基于深度学习的监督分类器仍然表现出强大的性能。在多标签意图分类任务上,经过监督学习训练的BERT类模型,相较于采用少样本提示方法的生成式LLM,在准确度和稳定性方面往往具有更高的性能优势。因此,DL模型仍是智能家居高精度、低延迟意图分类任务中的重要基线。

1.3 大语言模型(LLM)

面向智慧家庭的语义理解长期受限于口语化表达、模糊不完整指令,以及多设备并发操作等挑战。近期研究将LLM的推理与生成能力引入智能家居,以期在自然表达与复杂任务之间建立桥梁。一方面统一传统管线中“NLU(命令解释)+NLG(自然语言响应)”的多模块复杂度,另一方面借助上下文检索与范式化提示(prompting)增强消歧与任务分解能力。

目前已有大量学者正致力于利用大模型先进的自然语言处理能力,解决意图理解的难题。AwareAuto将用户的自然表达标准化为可读的上下文文本,再由LLM完成从语义推理到自动化方案生成的两步推理。在不牺牲自然性的前提下,覆盖动态参数、条件分支与时序约束等复杂规则,并强调可执行性约束与可行性校验^[19]。Sasha系统采用LLM支持的多阶段推理流程(如设备选择、例程验证、计划生成),在开放式、模糊目标中展示了LLM驱动的创意目标导向推理与人机协作潜力,并通过用户研究验证其能力与局限^[20]。SAGE应用提示树(prompt tree)和离散动作序列处理复杂任务,由LLM动态生成并裁剪信息、决定下一步动作与终止条件,并强调将指令映射为可执行调用(grounded execution),提高信息检索、用户交互与设备控制的一致性^[21]。HomeBench方法聚焦有效/无效指令和单/多设备的真实痛点,要求模型把自然语言直接映射为结构化设备调用或正确拒识^[11]。

基于上述代表性系统,当前智慧家庭意图理解在实现路径上呈现出若干共性做法:其一,借助上下文构造与提示工程,将房间、设备与状态等约束结构化注入并配合少样本示例以降低幻觉与格式错误^[19];其二,采用检索增强生成(Retrieval-Augmented Generation, RAG),仅召回与当前任务相关的设备与场景以缓解上下文冗余与窗口限制^[22,11];其三,结合参数高效微调与小样本适配,在兼顾泛化与算力开销的同时提升执行稳定性^[11]。

尽管LLM已经能更灵活地处理更自由的智慧家庭语音交互指令,但仍存在一些局限,需要解决:(1)对无效和并发指令的处理不足,多设备协同、冲突化解与顺序规划仍是难点;(2)模型幻觉会导致生成不存在的设备或输出不支持的动作,在长上下文下更易发生,需更强的输出约束与校验;(3)在拥有大量设备、房间、接口的高维家庭环境中,上下文窗口与检索误差叠加,影响可扩展性与鲁棒性。因此,需要建立针对这些问题的评测体系,以客观定位缺陷、量化改进空间并指导工程落地。

2 评测体系的构建要素与方法

在评测体系中,智慧家庭意图理解任务已从传统的意图识别与槽位填充(Intent & Slot Filling),演进为基于大模型的指令到控制序列生成的新范式。其目标是完成两个相互关联的关键任务:一方面,识别和预测用户的核心意图(Intent),即用户操作或请求的目的;另一方面,预测口语话语中的结构化信息,即抽取对应的槽位(Slot)及其值(Value),并将这些信息最终转化为可执行的控制序列(如设备调用或正确拒识),以检验“听懂到能执行”的端到端能力。因此,对智慧家庭意图理解能力的评估,重点在于数据集的构建、评测指标的设计和评测方法的选择。

2.1 数据集

面向智慧家庭语音交互意图理解的公开数据资源呈现出两条主线:(1)指令语料数据集,用于训练/评测识别与NLU;(2)文本到槽位与控制序列数据集,从自然语言文本映射到意图、槽位(分类与序列标注)及可执行控制序列(设备调用/参数/拒识)的数据集与评测基准,用于检验“听懂到能执行”的端到端能力。

指令级语料主要服务于语音识别与基础命令理解,多为语音或短文本形式,通常不含意图/槽位/可执行性标签。中文侧以AIShell-1/2/3为代表,覆盖普通话及家居/工业类常见指令(如开灯、调温、家电开关等),适用于ASR建模、口音鲁棒性与命令词覆盖分析,但因缺乏意图与设备动作标注,无法直接用于意图分类、槽位抽取或控制序列生成的评测^[23-25]。英文侧的Home-Assistant-Requests^[26]与Kaggle Smart-Home-Commands(约6k)^[14,27]属于轻

量指令文本集,提供如类别、时间、指令语句等字段,便于做入门级的分类与字段抽取原型;但二者多为单轮、单模态,缺少无效/并发指令、可执行性与设备约束等关键标注,难以覆盖真实家庭场景下的执行闭环评测。因此,指令级语料更适合作为识别与基础NLU的“前置资源”,在面向“文本到槽位/控制序列”的执行导向评测时,仍需结合带有意图/槽位乃至可执行约束的强化数据集或自建标注。

文本到槽位和控制序列的数据集与评测聚焦从自然语言到结构化语义与可执行动作的闭环能力。从文本到槽位的数据集,包含意图分类与槽位抽取,有面向中文场景可用中国计算机学会的智能人机交互自然语言理解数据集^[28](1.2万条)开展监督或半监督评测,常用Intent Accuracy、Slot F1、Joint Accuracy等指标,适合作为中文NLU基线;其局限在于多为单轮/轻上下文,且缺少设备能力、接口与可执行性(grounding)标签,无法直接度量“理解后能否正确执行”。从文本到控制序列的数据集(从指令生成设备调用/参数或拒识),以HomeBench^[11]为代表:在给定房间/设备/状态上下文下,要求模型对“有效/无效×单/多设备”四类任务输出严格匹配的结构化调用(如light.set_brightness(30)或error_input),评测采用Exact-Match控制序列准确率、无效指令识别率、(多设备)任务成功率及错误类型分析等;其优势在于把评测重心由是否听懂推进到能否正确、稳定地执行,但仍受虚拟/模拟环境、英文语料与品牌/协议单一所限,对多设备协同、冲突化解与顺序规划尤为敏感,并对RAG检索误差与长上下文稳定性高度依赖。综合来看,文本到槽位适合作为高精度、低时延的意图分类基线,文本到控制序列更贴近真实执行闭环;两者结合,方能系统刻画智慧家庭语音交互从“理解”到“落地”的全链路能力。

综合现有中文与英文资源可见,智能家居语音交互-意图理解的数据集存在一系列结构性短板:其一,标签缺口突出,诸多指令语料仅有转写或轻量字段,缺少意图槽位与可执行性的一体化标注,难以支持从理解到执行的闭环评测;其二,现有数据集难度单一,真实场景常见的无效指令、并发指令、冲突化解、顺序规划、指代模糊、二义性澄清、省略消解覆盖不足,多为单轮、单模态,多轮上下文与记忆演化的评测标注稀缺;其三,高维与异构挑战明显,在大量设备、房间、接口的场景下,评测对长上下文稳定性与检索增强召回误差高度敏感,且跨场景差异刻画不足,削弱可扩展性与外部效度;其四,可比性欠缺与难度刻画缺失,现有数据集在指令与环境构造等元信息方面的难度构建就没有统一评判,缺少可度量的任务难度分级致使跨数据集、跨论文的对比难以对应到一致的任务难度水平,也无法形成清晰的学习曲线与能力边界评估。此外,值得

表1 代表性智慧家庭语音交互意图理解代表性公开数据集

数据集	类别	语种	数据标注	典型用途	关键局限
AlShell-1/2/3 ^[23-25]	指令级	中文	语音转写指令文本	语音识别、命令词覆盖	不可直接做意图/执行评测
Home-Assistant-Requests ^[26]	指令级	英文	指令文本, 动作, 时间 文本字段	轻量抽取、规则原型	无无效/并发/可执行性
Kaggle Smart-Home-Commands ^[14, 27]	指令级	英文	指令文本, 类别, 动作, 时间	分类、字段抽取	规模有限、口径不一
智能人机交互自然语言理解数据集 ^[28]	文本到槽位	中文	指令文本, 意图分类, 对话要素	中文NLU基线、迁移	缺设备约束/可执行性
角色要素抽取-家电子集 ^[30-32]	文本到槽位	中文	群聊角色要素/论元	要素、槽位抽取参考	指令较为初级
HomeBench ^[11]	文本到控制序列	英文	指令文本, 调用设备, 调用参数, 报错类型	执行导向评测	模拟环境、品牌单一

注意的是, 随着LLM能力的飞速发展, 现阶段使用大模型自动化生成或辅助合成智慧家庭数据集的方法已被越来越多的使用以提升效率^[26, 11, 29]。表1列举了代表性公开数据集。

2.2 评测指标

对于智慧家庭语音交互意图理解的评测, 一般在文本到槽位与控制序列的数据集上对系统模型进行评测。评测体系将语义理解任务解耦, 采用三类核心评测项目来量化系统对指令的理解程度, 如表2所示。为量化上述评测项目的表现, 通常需要计算技术指标^[5], 如表3所示。

表2 智慧家庭意图理解核心评测项目

评测项目	衡量目标	常用核心指标
意图识别 (Intent Classification)	衡量能否正确判断出用户语句的核心目的或类别。	意图准确率 (Intent Accuracy), F_1 值
语义槽填充 (Slot Filling)	衡量能否在确定意图后, 正确提取出执行该操作所必需的参数、实体或细节。	槽位 F_1 值 (Slot F_1)
整句语义联合评测 (Joint Evaluation)	评测意图和句子中所有语义槽是否被同时、完全正确地识别和提取, 能直接反映用户体验。	联合准确率 (Overall Accuracy)

表3 意图理解评测任务基础量化指标

指标名称	衡量目标
准确率 (Accuracy)	总样本数预测正确的样本数。衡量系统整体判断正确的比例。
精确率 (Precision)	查准率。衡量系统判定为正确的样本中, 实际正确的比例 (避免误判)。
召回率 (Recall)	查全率。衡量所有实际正确的样本中, 系统成功捕捉到的比例 (避免漏判)。
F_1 值 (F_1 -Score)	精确率和召回率的调和平均值。是评估模型性能最常用的综合指标。

在实际评测中, 可采用评估意图与槽位 (单任务指标) 或联合评估 (整体准确率), 并通过交叉验证或固定划分来获取输入, 以确保在统一尺度上进行比较, 并保证结果的可复现性。

鉴于智能家居指令中普遍存在类别不平衡问题 (部分高频家电品类指令远多于低频家电品类指令), 在意图识别和语义槽填充这两项任务中, 评测结果应重点报告 F_1 值, 以避免多数类对整体性能产生过度影响。近年来, 随着预训练模型的兴起, 许多工作在上述指标上进一步引入类别权重、知识蒸馏、迁移学习等技巧, 以缓解中文数据不平衡和小样本问题, 但评测框架仍保持对意图准确率、

槽位 F_1 值、联合准确率的统一标准^[15, 33]。

鉴于语义理解的成功并不等同于用户任务的完成, 对于完整的智慧家庭链路, 评测体系需扩展至评估后续的行动规划和设备执行的准确性。这主要通过指令到控制序列生成 (Sequence-to-Control, S2C) 任务来实现。S2C任务设计用于评估系统在单/多设备、有效/无效指令以及顺序与约束一致性等复杂场景下的表现。评估指标包括Exact-Match准确率、可执行性校验 (Grounding) 及错误类型分布分析, 从而构成从语义到执行的闭环评测。此任务与交互式仿真评测范式高度契合, 是衡量系统端到端执行能力的关键。

2.3 评测方法

为构建一套兼顾技术准确性与应用有效性的智慧家庭语音交互意图理解评测体系, 通常将评测方法解耦为顶层评测范式和底层评测维度与任务设计两大部分。

2.3.1 评测范式

评测范式定义了评估工作的顶层形态和环境, 决定了测试的成本、可复现性与外部效度。

(1) 离线静态评测 (Offline/Static)

该范式基于标注语料的批量、单次测评, 主要适用于评估意图/槽位识别、排序, 以及文本到控制序列映射等任务。该范式通常采用固定数据集划分或交叉验证来保证结果的可复现性和代表性。其优点是可复现性高、测试成本低、效率高; 但缺点是难以覆盖真实交互中的不确定性、上下文和设备状态约束。

(2) 交互式仿真评测 (Interactive-in-Sim)

该范式在虚拟环境或仿真设备中进行闭环对话评测, 关注过程与结果。其评测输入主要依赖于事先设计好的场景脚本和状态序列数据集, 通过模拟用户与设备的实时交互来获取执行数据, 适合评估控制序列生成、多设备协同、状态追踪等复杂能力。核心观测指标包括任务完成率、纠错轮次、执行时延, 以及可执行性验证。

(3) 在线/实地评测 (Online/Field)

该范式在真实设备与真实用户中测量端到端效果, 其评测数据直接来源于真实用户流量日志和A/B测试分组。为确保对大规

模日志分析的准确性和代表性，数据处理常采用代表性抽样或分层抽样等统计方法，以控制用户地域、设备类型或使用频率等因素的干扰。此范式通过收集用户在实际使用中的行为和反馈来获取评测指标，因此外部效度最高。除基础技术指标外，核心指标还包括成功率、中断率、用户满意度（Mean Opinion Score, MOS和Net Promoter Score, NPS）与安全拒识表现^[34]。

2.3.2 评测流程

评测流程是将数据集和指标转化为系统性能报告的执行路径。无论采用何种评测范式，通用的评测流程通常包括若干个关键阶段。

评测准备阶段，需根据所选用的评测范式（离线、仿真或在线），准备相应的输入数据，例如固定测试集、交互场景脚本或实时用户流量采样。同时，必须明确待测系统的版本，并设定用于横向对比的基线模型（Baseline），以确保结果具有参照性。

系统运行与结果记录阶段。在此阶段，将测试集或场景脚本输入到待测系统或模拟环境中，并实时记录系统对每条指令的输出结果，包括预测的意图标签、提取的语义槽位、控制序列，以及关键的识别响应时间。

结果比对与指标计算阶段。此阶段要求将系统输出与预先标注的黄金标准（Ground Truth）进行逐条、逐槽位的严格比对。需严格按照评测指标中定义的公式，计算核心技术指标；对于动态评测，则需计算任务完成率、纠错轮次等流程指标。

数据分析与报告生成阶段。在此阶段，需对评测失败的样本进行分类，深入分析系统在模糊意图、多指令并发、指代消解等复杂交互范式下的弱点。最终，汇总所有指标，生成详细的评测报告，清晰呈现待测系统相对于基线模型的性能增益，并指导后续优化方向。

3 关键挑战

随着大模型的发展，智能家电语音系统从固定指令走向自然交互的人本位方向。行业标准提出固定操控、泛化功能、交互三级智能等级，为评测设定了更高目标。现有评测体系的核心挑战在于完成从技术性能指标到人本位智能指标的跨越，从功能性量化转向智能程度量化，在复杂家庭交互中衡量类人推理与决策能力^[3]。行业的终极目标是人与人对话式的自然体验，评测必须同步进化，真实反映系统在复杂情境下的实际智能水平，确保高分能够转化为低干扰与高满意度的真实体验。

3.1 从人本位出发的智能程度量化难题

智能程度量化是评测体系面临的核心挑战：传统的正确率评测

指标虽然能衡量模型的技术性能，但难以捕捉用户对智能的主观感受和系统的类人思维能力。主要面临情感层评测和智能等级量化量大挑战^[35]。

功能层向情感层的发展：评测需要从仅仅关注系统是否执行了正确的操作的功能层，升级到评估系统能否理解用户的情绪、意图背后的真实动机，并提供具备情感和个性化响应的情感层。

智能等级的量化鸿沟：如何设计指标，有效区分系统在泛化和交互这两个高阶智能等级上的表现差异，而不仅仅是简单地计算准确率。当前常用评测集普遍缺少难度切片的系统化标注，例如家庭规模、上下文长度、含糊度、并发冲突密度等，因而得分难以映射到清晰的能力边界，无法准确反映模型在高阶智能上的真实差异^[36]。

3.2 复杂交互范式下的能力覆盖难题

自然的人机对话并非单轮指令，而是涉及多项高阶认知能力。当前的评测体系难以全面、系统地覆盖相关能力。

记忆与上下文推理：评测必须能够衡量系统在多轮对话中对历史信息（记忆）、用户习惯和设备状态（上下文）的保持和推理能力。例如，用户在前一句提及“客厅的灯”，系统在后一句的“把它们关掉”中是否能准确地指代回溯，并执行正确的操作。

多指令并发与顺序规划：评测体系需要验证系统处理复杂指令序列的能力。这不仅包括识别用户一次性发出的多条指令（例如：“打开电视，把空调调到26度”），还包括对这些指令进行逻辑拆解、优先级排序，并规划出正确的执行顺序的能力。

模糊意图处理：模糊意图（“我有点冷”）的能力，尤其需要系统结合环境感知（如室温）进行感知推理。

多设备协同与复杂情境：家居场景模式类的指令往往涉及多设备协同。评测需要设计场景来衡量系统是否能根据一个抽象指令（如“开启影院模式”）正确地触发多个设备的联动操作（例如：关闭灯光、打开电视、降低窗帘），并具备冲突解决的能力（例如：在执行指令时发现设备离线或处于非预期状态）。

二义性澄清与问答策略：评测体系必须评估系统在面对用户表达中的二义性或信息缺失时，能否采取高效、自然的策略进行澄清和引导。例如，当用户说“开灯”而环境中存在多盏灯时，系统应能主动询问“您想开客厅的灯还是卧室的灯？”。

错误指令与状态回溯：评测需要验证系统对用户发出的无效指令（例如：虚构设备、越权操作）或设备执行失败时的处理能力。包括能否准确识别无效指令并进行安全拒识；能否在设备返回错误状态（例如：设备离线、操作失败）时，向用户提供清晰的反馈，并具备状态回溯能力，帮助用户快速从错误状态恢复到成功的交互路径。

3.3 评测语料的构建和标准化挑战

支持高阶智能评测的语料构建难度极大,缺乏统一的行业标准,主要体现在几个方面。

语料的稀缺:与大量的单轮指令数据相比,包含多轮、回指、纠错,以及复杂家庭情境和感知型推理(如“我出门了”)的高智能等级交互语料仍十分稀缺。

标注的复杂性与主观性:复杂情境不仅需要意图与槽位标注,还需同步标注上下文世界状态、推理路径、协同行为与执行约束,这些高阶标注在客观性与一致性上难以保证。

用户体验与主观满意度量化:现有评测体系难以充分捕获用户体验的友好度和情感接受度。用于评估主观感受的语料(如带有情感色彩、满意度评分或用户打断/重试记录的交互序列)极度缺乏,这使得评测难以从技术本位转向人本位。如何将用户对交互的流畅性、自然度以及系统低干扰性的主观评价,转化为可量化的、可复现的评测数据集和标准,是当前语料构建和标准化面临的又一大挑战。

为提升评测体系的科学性和可比性,未来的标准化工作应聚焦于以下方面:(1)标准化与透明化:横向可比性差的根源在于数据切分与难度口径不统一。展望是公开并固定数据切分与评测脚本。

(2)建立可解释的对照带:同时提供两类强基线:传统深度学习基线用于意图与槽位,LLM 控制序列基线用于执行闭环,形成可解释的对照带,以评估新范式的增益。(3)体验量化:在情感层面和体验层面应进行边界化量化,限定与交互质量直接相关的情感信号与策略,确保高分能够转化为低干扰和高满意度的真实体验。

3.4 关键能力评估维度

为实现向人本位智能的跨越,未来的评测体系应朝着系统地覆盖以下关键能力维度发展,以弥补现有评测方法的不足,并作为衡量系统智能程度的标尺:

(1)语义鲁棒性:评估系统在面对用户自然表达的变异时的稳定性。重点测试对语句变体、同义句、省略句、指代回溯以及口语化、不规范表述的理解能力。该能力可通过辅以对抗性/扰动测试(例如:引入随机同义词或语义陷阱),来量化 NLU 模型对语义噪声的抵抗能力。

(2)泛化能力:评估系统对未见指令和新情境的适应能力。重点测试:对域外(Out-of-Domain, OOD)指令的正确拒识或转移能力;对未见设备/接口的小样本(Few-Shot)或零样本(Zero-Shot)泛化能力;将知识迁移应用到更复杂的多指令并发、跨设备协同等新组合情境中的能力。

(3)上下文与多轮能力:此维度测试模型对照应、省略、状态

追踪及多轮对话引导的能力。需要强调的是,多轮交互是重要的评估维度而非独立的范式。

(4)安全与拒识表现:测试系统对危险操作、越权操作的拒识和降级策略。通过红队测试,权衡误拒率(False Rejection Rate)与误接受率(False Acceptance Rate)的风险。

(5)人机协同与纠错效率:评估模型的澄清恢复策略、交互轮次、以及从错误状态恢复到成功的恢复率(Recovery Rate)。

(6)系统资源与实时性(System Dimension):作为系统层面的辅助维度,关注端侧/云侧资源开销、延迟、吞吐量、内存占用与能耗,以评估其对实时语音交互体验的影响。

4 结论与展望

本文综述了智慧家庭语音交互意图理解的评测现状:评测关注点正从技术准确率转向执行闭环与人因体验,数据与方法从指令级转向文本到槽位与控制序列的端到端评估。本文指出,任务覆盖、难度刻画与可比性是当前瓶颈,高维与异构环境对检索增强与长上下文稳定性提出挑战,安全拒识与低干扰交互亟须纳入统一报告口径。未来工作应优先推进三项工程化建设:

一体化数据与脚本标准:发布含难度元数据的标准数据与评测脚本,固定切分;同时提供两类强基线,覆盖高精度意图分类与控制序列生成,支撑可比与可复现。

统一指标与报告协议:设定最小必报集(意图准确率、槽位 F_1 、联合准确率、无效识别率、多设备成功率、澄清恢复率、拒识率与格式合规率),固定难度切片与解码配置,并报告置信区间与重复次数。

仿真与真实小样本之间建立可迁移验证路径,注入品牌与协议异构、感知缺失与时延噪声,使评测分数更可信地映射到真实体验。

总之,智慧家庭意图理解的评测体系正处于由技术本位向人本位转型的关键时期。未来,随着 LLM 技术的广泛应用,评测不再仅仅是衡量算法的准确率,更是对系统安全、伦理、资源消耗和情感友好度的全面检验。通过上述三项工程化建设,可以有效解决当前数据集的结构性短板和标准化挑战,最终推动评测结果更可信、更可比、更具指导性,从而加速整个行业向“人与人对话”式的自然体验的终极目标迈进。

参考文献

- [1] 焦利敏,李红伟,曲宗峰,等.基于DeepSeek推理大模型的智能家电智能体技术路线及应用[J].家电科技,2025(01):43-47.
- [2] 智能家用电器的语音交互技术 第1部分:通用要求[S].GB/T 45354.1—2025.国家

- 市场监督管理总局, 国家标准化管理委员会, 2025-04-14.
- [3] 智能家用电器的语音交互技术 第2部分: 测试方法[S]. GB/T 45354.2—2025.国家市场监督管理总局, 国家标准化管理委员会, 2025.
- [4] 信息技术 智能语音交互测试方法 第2部分: 语义理解[S]. GB/T 41813.2—2022.国家市场监督管理总局, 国家标准化管理委员会, 2022-10-12.
- [5] 人工智能大模型 第2部分: 评测指标与方法[S]. GB/T 45288.2—2025.国家市场监督管理总局, 国家标准化管理委员会, 2025-02-28.
- [6] Li, J., Chen, C., Rahimi Azghadi, M. et al. Security and Privacy Problems in Voice Assistant Applications: A Survey[J]. Computers & Security, 2023, 134.
- [7] Dutsinma, F. L., Pal, D., Funilkul, S. et al. A Systematic Review of Voice Assistant Usability: An ISO 9241-11 Approach[J]. SN Computer Science, 2022, 3(04).
- [8] Rocha, A. P., Ketsmur, M., Almeida, N., & Teixeira, A. An Accessible Smart Home Based on Integrated Multimodal Interaction[J]. Sensors, 2021, 21(16): 54-64.
- [9] 周少龙, 刘广通, 窦方正, 等. 长上下文学习在家电知识问答中的应用[J]. 家电科技, 2024(zk): 445-448.
- [10] 焦利敏, 刘泽超, 顾子谦, 等. 智能家电语音交互能力测试语料库建设的研究[J]. 家电科技, 2022(zk): 130-134.
- [11] 李思琳, 郭宇航, 姚家树, 等. Home Bench: Evaluating LLMs in Smart Homes with Valid and Invalid Instructions Across Single and Multiple Devices[OL]. 计算机科学. 自然语言处理, 2025: arXiv:2505.19628.
- [12] Salton, G., Buckley, C. Term-weighting approaches in automatic text retrieval[J]. Information Processing & Management, 1988, 24(05): 513-523.
- [13] Mikolov, T., Sutskever, I., Chen, K., et al. Distributed representations of words and phrases and their compositionality[A]// In Advances in Neural Information Processing Systems[C], 2013: 3111-3119.
- [14] Mochurad L, Babii V, Greguš M. Machine Learning Models for the Recognition of Commands in Smart Home Technologies[A]// CEUR-WS[C], 2024, 3699: 70-87.
- [15] Tian M. Understanding and Implementing Smart Home Voice Commands and Intent Recognition Based on Deep Learning[J]. Applied and Computational Engineering, 2025, 146(01): 187-194.
- [16] Zhao J, Wen Y, Li Q, et al. Deep learning approaches for multimodal intent recognition: A survey[EB/OL], 2025: arXiv preprint arXiv:2507.22934.
- [17] Zheng Y, Chen G, Huang M. Out-of-Domain Detection for Natural Language Understanding in Dialog Systems[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2020, 28: 1198-1209.
- [18] Luger E, Sellen A. Like Having a Really Bad PA: The Gulf between User Expectation and Experience of Conversational Agents[A]// Proceedings of the 2016 CHI Conference on Human Factors in Computing Systems (CHI 2016)[C], 2016.
- [19] Shi Y, Liu X, Yu C, et al. Bridging the gap between natural user expression with complex automation programming in smart homes[EB/OL], 2024: arXiv preprint arXiv:2408.12687.
- [20] King E, Yu H, Lee S, et al. Sasha: Creative goal-oriented reasoning in smart homes with large language models[A]// Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies[C], 2024, 8(01): 1-26.
- [21] Rivkin D, Hogan F, Feriani A, et al. SAGE: Smart Home Agent with Grounded Execution[EB/OL], 2023: arXiv preprint arXiv:2311.00772.
- [22] Lewis P, Perez E, Piktus A, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks[A]// In: Advances in Neural Information Processing Systems[C], 2020, 33: 9459-9474.
- [23] Bu H, Du J, Na X, et al. AISHELL-1: An open-source Mandarin speech corpus and a speech recognition baseline[A]// In: Proceedings of the 20th Conference of the Oriental Chapter of the International Coordinating Committee on Speech Databases and Speech I/O Systems and Assessment (O-COCOSDA)[C], 2017-11-01, Seoul, Korea. IEEE, 2017: 1-5.
- [24] Du J, Na X, Liu X, et al. AISHELL-2: Transforming Mandarin ASR research into industrial scale[EB/OL], 2018: arXiv preprint arXiv:1808.10583.
- [25] Shi Y, Bu H, Xu X, et al. AISHELL-3: A multi-speaker Mandarin TTS corpus and the baselines[EB/OL], 2020: arXiv preprint arXiv:2010.11567.
- [26] Home-Assistant-Requests [DB/OL]. Hugging Face. Retrieved 2025-10-16, from <https://huggingface.co/datasets/acon96/Home-Assistant-Requests>.
- [27] Smart Home Commands Dataset [DB/OL]. Kaggle. Retrieved from <https://www.kaggle.com/datasets/bouwecceunen/smart-home-commands-dataset>.
- [28] 智能人机交互自然语言理解数据集 [DB/OL]. DataFountain. Retrieved from <https://www.datafountain.cn/competitions/511>.
- [29] 唐杰, 贾巨涛, 李立辉, 等. 智能语音交互中的多意图解析技术研究[J]. 家电科技, 2024(zk): 418-421.
- [30] 讯飞开放平台. 基于星火大模型的群聊对话角色要素提取挑战赛[EB/OL]. 科大讯飞股份有限公司, 2024-06-09 [2025-09].
- [31] smart_home_control [DB/OL]. Hugging Face. Retrieved 2025-10-16, from https://huggingface.co/datasets/Charles95/smart_home_control.
- [32] CSDN 博客: 智能家电语音交互技术文章[EB/OL], 2025. URL: <https://blog.csdn.net/yyyy2711/article/details/140211501>.
- [33] Chakraborty S, Chakraborty D. Alexa's Voice Command (Intent) Customization For Our Smart Home[J]. World Wide Journal of Multidisciplinary Research and Development, 2025, 11(03): 76-83.
- [34] Zhang Z, Lei L, Wu L, et al. SafetyBench: Evaluating the safety of large language models with multiple choice questions[A]// In: Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Vol 1: Long Papers)[C], 2024, Bangkok, Thailand: 15537-15553.
- [35] 焦利敏, 任兆亨, 李红伟, 等. 生活场景驱动的AI智能家电的新研究范式[J]. 家电科技, 2025(03): 85-89.
- [36] 李伟, 贾奇伟, 劳春峰, 等. 基于LLM的家电智能交互控制系统研究[J]. 家电科技, 2024(zk): 125-129.